Утечка данных

Апполонина Екатерина

Группа: 23Б-11

Предмет: «Интеллектуальные системы»

Содержание

01
Вступление

02
Типы утечек

03
Причины утечек

04
Последствия

05
Как выявить утечку

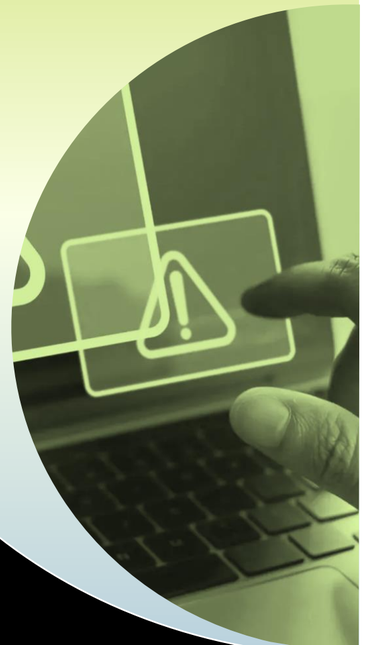
06
Признаки утечки

07
Предотвращение

08
Ссылки на источники







Вступление

Утечка данных – ситуация, когда модель во время обучения получает доступ к информации, которая не будет доступна ей в момент реального прогнозирования.

Это приводит к тому, что прогностическая модель кажется точной до тех пор, пока не будет применена в реальных условиях; она будет давать неточные результаты, что приведет к принятию неверных решений и ложным выводам.

Типы утечек

Target Leakage

Признак содержит информацию о будущем или о самом целевом событии.

Train-Test Contamination

Информация из тестовой выборки «просачивается» в процесс обучения.

Feature Leakage

Это частный случай, когда признак содержит информацию, недоступную в момент прогнозирования

Целевые утечки

Данный вид утечек связан с непреднамеренным или ошибочным использованием информации о целевой переменной, которая не будет доступна по завершении процесса обучения.

Тривиальный случай — включение целевой переменной в обучающий набор в качестве входного признака. Функция, которую модель должна «научиться» воспроизводить, явно задана на обучающей выборке и не будет доступна вне ее.

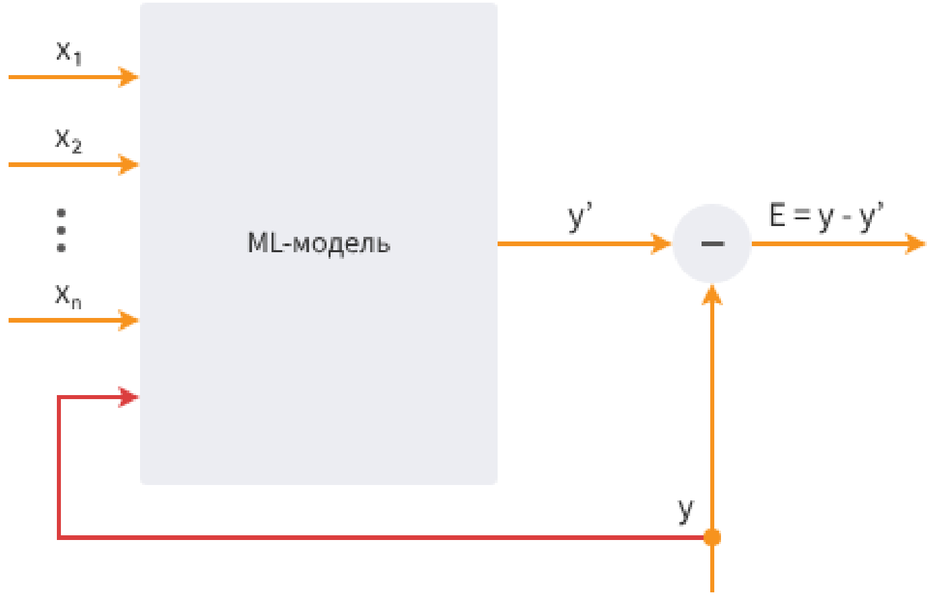


Рис. 1 Целевая утечка

Утечка обучающего/тестового множества

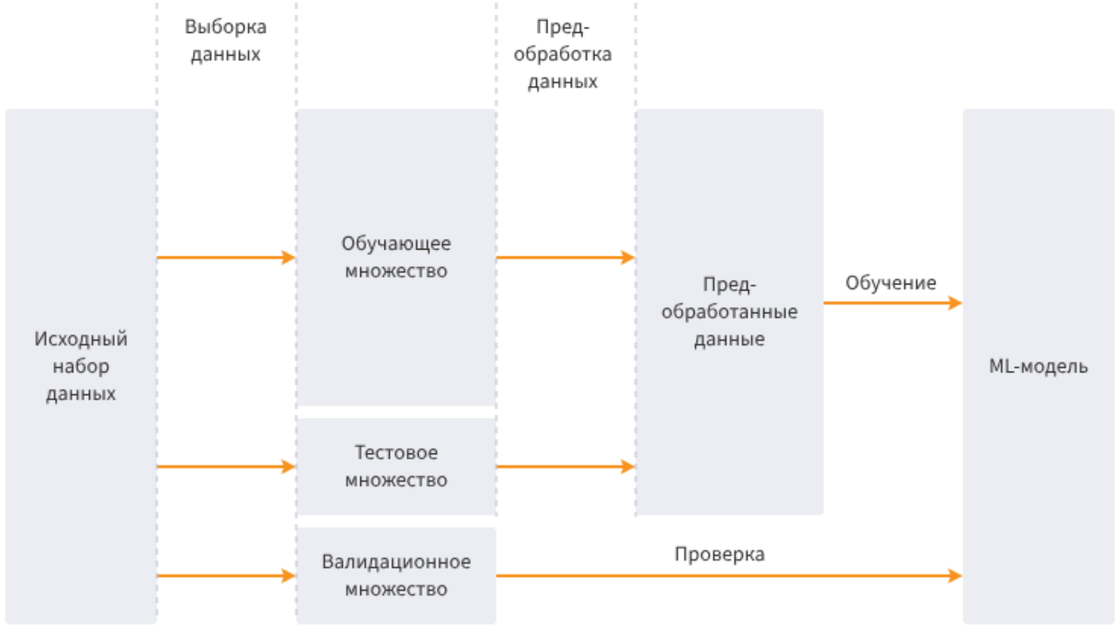


Рис. 2 ТТС – утечка

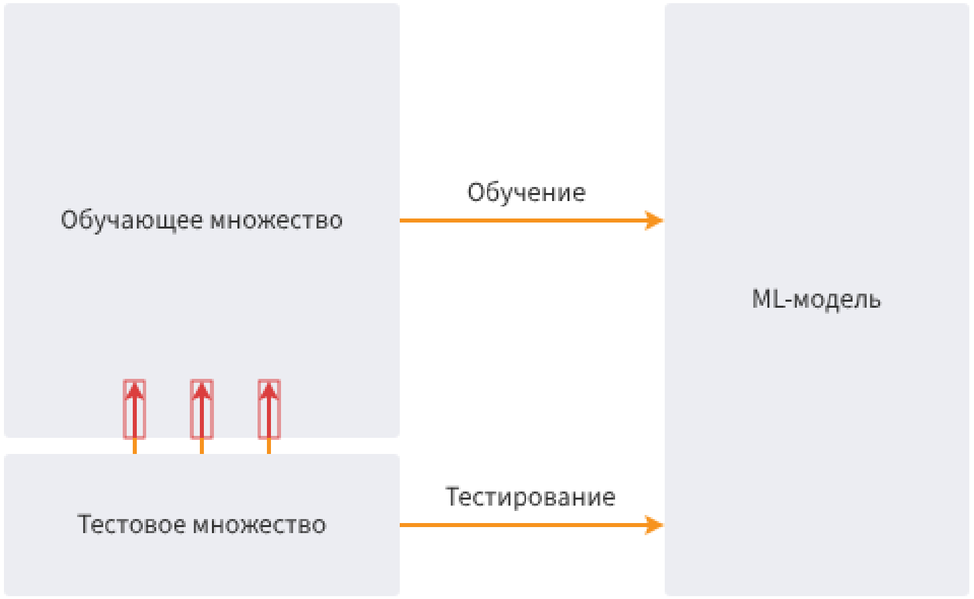


Рис. 3 Утечка тестовых данных в обучающие

Утечка признаков

Признаки обучающего набора данных, доступные на этапе построения модели, оказываются недоступными при её эксплуатации. Этому в наибольшей степени подвержены данные, формируемые во внешнем окружении, доступность которых не зависит от самой организации. Однако, если такие данные игнорировать, потенциально ценная информация из внешнего окружения останется неиспользуемой при обучении модели, что снизит ее качество.

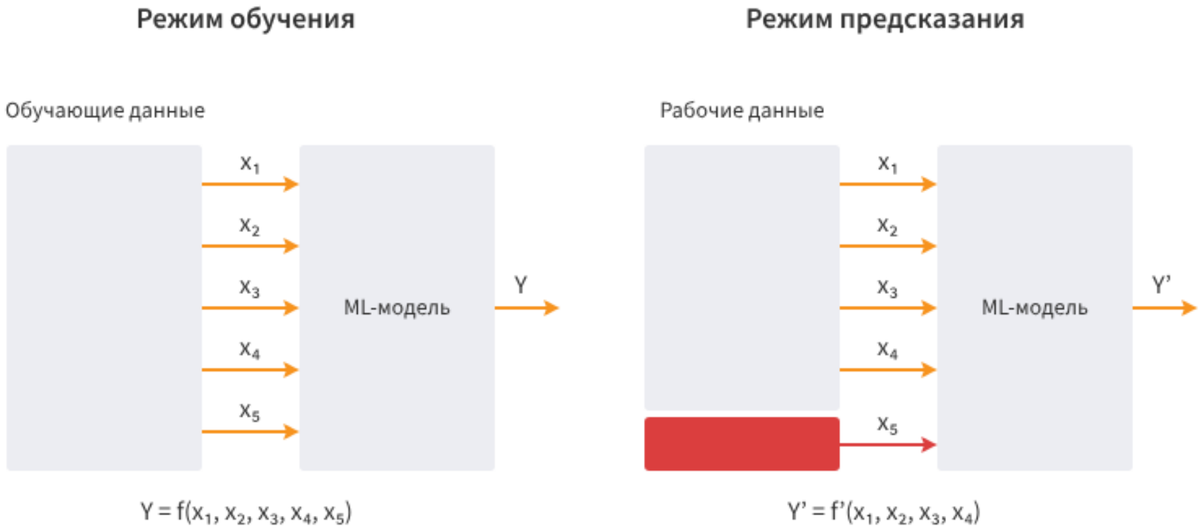


Рис. 4 Утечка признаков

Причины утечки данных

- Учет будущей информации
- Неправильный выбор признаков
- Загрязнение внешними данными
- Ошибки предварительной обработки данных
- Некорректная перекрестная проверка
- Нормализация до разделения
- Утечка информации при валидации и изменениях процесса

Последствия

- Плохая обобщающая способность на новые данные:
- Предвзятое принятие решений
- Ненадежные выводы и результаты
- Завышенные показатели производительности
- Расточительность в использовании ресурсов
- Потеря доверия пользователя
- Юридические риски, риски, связанные с соблюдением нормативных требований

Как выявить утечку?

- **Подготовка**: данные должны быть правильно разделены, а этапы предварительной обработки следует применять только к обучающему набору данных.
- **Поиск**: необходимо исследовать подозрительные закономерности, которые могут указывать на утечку информации. Проанализировать важность признаков и поведения модели, чтобы выявить любые нереалистичные взаимосвязи.
- **Тестирование**: если при тестировании модели на реальных данных производительность значительно снижается, то это может указывать на утечку данных во время обучения.

Признаки утечки

- Необычайно высокая производительность
- Расхождение между результатами обучения и тестирования
- Несогласованные результаты перекрёстной проверки
- Неожиданное поведение модели

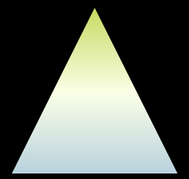
Предотвращение

- Разделять данные до любых преобразований
- Использовать Pipeline (scikit-learn) — preprocessing только на train
- Применять кросс-валидацию с учетом времени (TimeSeriesSplit)
- Проверять признаки на причинно-следственную связь
- Использовать отдельный контрольный набор, который не трогают до финала
- Проводить аудит данных и пайплайна

Ссылки на источники



Loginom



IBM



Scikit-learn